

**FEEDBACK IMPLÍCITO NO APRENDIZADO**  
***ONLINE* PARA RECOMENDAÇÃO DE MÚSICAS**

BRUNO LAPORAIS PEREIRA

FEEDBACK IMPLÍCITO NO APRENDIZADO  
*ONLINE* PARA RECOMENDAÇÃO DE MÚSICAS

Proposta de dissertação apresentada ao Programa de Pós-Graduação em Ciência da Computação do Instituto de Ciências Exatas da Universidade Federal de Minas Gerais como requisito parcial para a obtenção do grau de Mestre em Ciência da Computação.

ORIENTADOR: RODRYGO LUIS TEODORO SANTOS

COORIENTADOR: NIVIO ZIVIANI

Belo Horizonte

Novembro de 2015

# Sumário

<b>1</b>	<b>Introdução</b>	<b>1</b>
1.1	Definição do Problema . . . . .	2
1.2	Motivação . . . . .	3
1.3	Proposta . . . . .	3
1.4	Organização do Texto . . . . .	3
<b>2</b>	<b>Trabalhos Relacionados</b>	<b>4</b>
2.1	Sistemas de Recomendação . . . . .	4
2.1.1	Recomendação de Músicas . . . . .	6
2.2	Aprendizado de Máquina . . . . .	7
2.2.1	Aprendizado Online e Reforço . . . . .	7
2.2.2	Aprendizado na Recomendação . . . . .	8
<b>3</b>	<b>Metodologia</b>	<b>10</b>
<b>4</b>	<b>Cronograma</b>	<b>12</b>
<b>A</b>	<b>Assinaturas</b>	<b>14</b>
	<b>Referências Bibliográficas</b>	<b>17</b>

# Capítulo 1

## Introdução

Os Sistemas de Recomendação têm apresentado grande evolução nos últimos anos, produzindo resultados sólidos sobre o cenário atual, tanto para mercado quanto em pesquisas científicas. Segundo Ricci et al. [2011], esses sistemas têm como objetivo a recuperação e sugestão de itens aos usuários, tendo como tarefa preditiva inferir o interesse sobre eles. Ou seja, apresentar itens, talvez desconhecidos, mas que atendam à expectativa de consumo do usuário.

Normalmente, o termo item é utilizado para representar o que será indicado ao usuário, ou seja, o que será recomendado. Contudo, os sistemas atuais possuem diversos itens recomendáveis, alguns da mesma família, como filmes, livros, músicas, ou sistemas *e-commerce* que possuem itens variados em seu catálogo [Ricci et al., 2011]. Para cada um desses itens, é possível perceber perfis distintos, ou seja, características importantes para explorar, mas específicas, tornando a tarefa de modelagem um desafio ainda bastante explorado.

Ainda em cenários onde os itens recomendáveis são da mesma família, é difícil definir as características que serão importantes para representação dos itens, assim como descartar características que causam ruído sobre a modelagem. Contudo, o objetivo é obter sinais ou fatores sobre as escolhas dos usuários. Da mesma forma, os usuários de cada sistema possuem necessidades de consumo específicas e apresentam características distintas no comportamento, nem sempre bem atendidas pelos sistemas. Além disso, é importante destacar que, ainda que fosse possível encontrar uma representação ideal para os usuários, as preferências do usuário podem variar ao decorrer do tempo, ou seja, a representação deve ser flexível e personalizada para cada usuário [Ricci et al., 2011].

No caso da recomendação de músicas, é possível consolidar esses desafios sobre um cenário real. Conforme [Celma, 2010], o comportamento dos usuários que conso-

mem música vem mudando drasticamente. Avanços tecnológicos podem ser notados, por exemplo, nos sistemas de *streaming* de música como *Spotify*, *Google Play Music* entre outros grandes sistemas na atualidade. Normalmente, o consumo de mídia nesse ambiente é realizado em segundo plano, ou seja, relaciona ao contexto em que o usuário está inserido para recomendar diferentes tipos de música trabalha ou dirige seu automóvel. Contudo, cada usuário possui preferências distintas, e mesmo em contextos semelhantes a recomendação deve ser personalizável.

Motivados pelos desafios da área pretendemos utilizar técnicas de Aprendizado de Máquina com o objetivo de produzir algoritmos que permitam recuperar padrões que descrevem os dados, produzindo um modelo adequado para tratar informações e prever comportamentos. Ou seja, permitir que o computador aumente sua eficácia em determinada tarefa [Murphy, 2012].

Um dos fatores mais importante em sistemas de recomendação se refere a utilização do *feedback* como forma de inferência da preferência do usuário. O *Feedback* ocorre na forma de interações entre o usuário e o sistema na forma sinais enviados pelo usuário. Em recomendação, podemos considerar dois tipos de *feedback*, o explícito e o implícito. Segundo Jawaheer et al. [2010], no contexto de recomendação de músicas, o *feedback* explícito pode ser observado quando um usuário expressa diretamente sua preferência sobre algumas músicas. Por outro lado, de forma mais abundante, o *feedback* implícito compõe as interações do usuário com o sistema ao utilizar os comandos de *play*, *skip*, etc.

## 1.1 Definição do Problema

O problema a ser resolvido está relacionado com sistemas de recuperação de música baseados em *feedback* implícito. O *feedback* implícito representa as interações do usuário com o sistema e suas preferências não são explicitamente expressas. Ainda que muito ruidoso, esses sinais carregam informações importantes sobre as preferências do usuário, fato que também será explorado pelo presente trabalho.

Com objetivo de atender o máximo de usuários possível, é necessário que os sistemas de *streaming* de música possuam um catálogo extenso de opções. Porém, esse fato promove diversos novos desafios tais como recuperar itens adequados para cada usuário. Ainda que esse problema fosse trivial, é importante destacar que as preferências dos usuários podem mudar, ou seja, itens "relevantes" no passado podem se tornar "irrelevantes" e itens similares podem não condizer com a necessidade do usuário. Contudo, quando os usuários desses sistemas são expostos a itens que não os

satisfaçam, normalmente são utilizados comandos de interação gerando *feedback*.

## 1.2 Motivação

Assim como apresentado na Seção 1.1, existe uma quantidade massiva de itens recomendáveis em sistemas de *streaming* de músicas, sendo este um dos desafios incentivadores para o presente trabalho. No entanto, a principal motivação é promover recomendações personalizadas sem a inferência explícita do usuário, com intuito de aumentar a satisfação ao interagir com esses sistemas. Ou seja, aproximar os itens recomendados da necessidade de consumo, utilizando sinais normalmente observados sobre o comportamento do usuário.

## 1.3 Proposta

O presente trabalho tem como objetivo melhorar a recomendação *online* por meio da utilização do *feedback* implícito. Sendo assim, propor um modelo personalizável, capaz de inferir preferências dos usuários sobre as músicas, e adaptável utilizando as interações do usuário para criação de um modelo de aprendizado online.

Os itens da presente proposta são: (i) Representação flexível, capaz de caracterizar as músicas e as preferências dos usuários; (ii) Permitir que o modelo seja reforçado com novas evidências; (iii) Capturar preferências dos usuários e reconhecer mudanças em seu comportamento; (iv) Estratégia de recomendação para produzir uma lista de músicas personalizada e adequada as necessidades do usuário.

## 1.4 Organização do Texto

A demais seções deste trabalho estão organizadas seguindo a formatação: O Capítulo 2 será dedicado à introdução dos conceitos básicos dos Sistemas de Recomendação e Aprendizado de Máquina, além de revisar os trabalhos relacionados a este. No Capítulo 3 serão expostos detalhes sobre nossa proposta, além de introduzir as metodologias utilizadas para avaliações iniciais. Por fim, no Capítulo 4, será apresentado o cronograma a ser cumprido ao decorrer do mestrado.

# Capítulo 2

## Trabalhos Relacionados

Neste capítulo serão formalizados os principais conceitos dos Sistemas de Recomendação e sobre as abordagens para Aprendizado de Máquina, com enfoque principal em trabalhos relacionados ao cenário apresentado pelo presente trabalho.

### 2.1 Sistemas de Recomendação

Claramente os Sistemas de Recomendação vem mudando a forma como os usuários interagem e consomem itens de um sistema. Segundo Ricci et al. [2011], Sistemas de Recomendação surgiu como área de pesquisa em meados da década de 90 e, é considerada uma sub área da Recuperação da Informação que discute sobre técnicas capazes de promover aos usuários de sistemas, que fornecem algum tipo de produto, sugestões de itens para consumo. Desta forma, o objetivo é apresentar itens que possivelmente atendam a necessidade de consumo dos usuários, ou seja, de prever suas preferências e gostos.

Ao longo dos anos, diversos métodos foram propostos com a motivação de tentar modelar as preferências dos usuários e características dos itens. Uma das principais famílias de métodos é a Filtragem Colaborativa, onde informações de colaboração entre os usuários é utilizada para capturar itens e usuários similares. Esse cenário pode ser facilmente visualizado por uma matriz de usuários por itens, sendo cada célula a representação de relevância, seja pela avaliação do usuário sobre um item, ou apenas binária. Seguindo este raciocínio foram desenvolvidos diversos trabalhos, assim como o de Herlocker et al. [1999], que explora a similaridade entre os usuários com base nos itens consumidos e/ou avaliados, e Sarwar et al. [2001] que propõe a utilização de um modelo baseado na similaridade entre os itens.

Ainda em relação a Filtragem Colaborativa, existem diversos trabalhos com propostas de técnicas usando fatoração de matrizes obtendo melhores resultados. Um dos principais trabalhos foi o Koren et al. [2009], desenvolvido pelos ganhadores da competição do *NetFlix* no 2009. Assim como na teoria de álgebra, a fatoração de matrizes permite decompor uma matriz completa no produto de outras menores que a original. No caso da recomendação, a ideia é reconstruir a matriz de usuários por item, contudo, como a matriz não está completa, esses métodos produzem fatores latentes permitindo que usuários e itens sejam representados sobre um mesmo espaço, permitindo então a predição. No caso do trabalhos de Koren et al. [2009], foram utilizados diversos métodos para fatoração e milhares de fatores latentes.

Entre atuais trabalhos baseados em fatores latentes, foi produzido Volkovs & Yu [2015]. As principais diferenças da abordagem é a utilização da técnica *Singular Value Decomposition (SVD)* para decomposição de matrizes, sobre o fato de que a matriz principal possui apenas dados binários, ou seja, a preferência sobre o item é implícita e representa apenas a interação dos usuários com itens. A abordagem proposta apresentou bons resultados em teste sobre diferentes base de dados, inclusive de músicas, superando modelos mais complexos e que utilizam de outras fontes para recomendação.

No entanto, as abordagens baseadas na Filtragem Colaborativa são falhas para predição sobre novos usuários ou itens. Nesse caso, não existem informações colaborativas e inviabiliza utilizar o método para recomendação. Contudo, outra grande família são os modelos Baseados em Conteúdo que, conforme o capítulo de Lops et al. [2011], são métodos capazes de modelar itens e usuários utilizando as informações de conteúdo, ou seja, informações descritivas como categoria, nome, etc. Portanto, mesmo nos casos de usuários ou itens novos, as informações para recomendação estão disponíveis ainda que com menos detalhes. Porém, como o método é baseado na similaridade de conteúdo, é produzida pouca diversidade.

Acima foram citados alguns dos principais métodos para recomendação, porém, existem diversos outras famílias também com seus prós e contras. Contudo, como nenhum modelo é capaz de solucionar todos os problemas, uma alternativa é a utilização de hibridização, ou seja, abordagens capazes de combinar os modelos [Burke, 2002]. Nesse cenário, com objetivo de repesar as predições de cada modelo, são bastante exploradas as técnicas de Aprendizado de Máquina que, também será assunto abordado por este trabalho.



### 2.1.1 Recomendação de Músicas

Existem diversos fatores que caracterizam o cenário de recomendação de músicas, como por exemplo a criação de uma sessão longa, a forma sequencial como as mídias são consumidas, etc. Normalmente, a música compõe uma tarefa de fundo, ou seja, apenas acompanha uma tarefa principal do usuário e, o objetivo do usuário dificilmente será interagir com apenas um item, mas sim sobre um conjunto de itens ou a sequência. Ainda como tarefa de fundo, existem frequentes interação, ou *feedback*, em que pode ser capturada de diversas formas, seja ela explícita ou implícita [Celma, 2010].

Conforme a pesquisa de Song et al. [2012], com a crescente evolução da tecnologia e os diversos formatos para consumo de mídias digitais, o cenário de recomendação de músicas atrai muita atenção, sendo foco de diversas abordagens na literatura. No entanto, os melhores resultados utilizam duas famílias de algoritmos, Filtragem Colaborativa e Modelos Baseados em Conteúdo, assim como descritos na seção 2.1.

Mesmo com grandes esforços de pesquisadores sobre a área de recomendação de músicas, ainda existem diversos problemas em aberto, sendo destacado principalmente métodos para melhorar o reconhecimento das necessidades e requisitos do usuário, ou seja, um modelo ainda mais personalizado. Dessa forma, explorar principalmente o contexto em que o usuário está inserido, promovendo diversificação e adequação das músicas recomendadas e as tarefas que estão sendo desenvolvidas.

Contudo, conforme as características descritas sobre o cenário de músicas em geral, recomendar apenas uma música não é a principal motivação e de fato não traduz o problema de recomendação nesse ambiente. Sendo assim, existem diversos trabalhos que realizam recomendação e geração explorando a ideia de sequências de músicas ou *playlist*, sendo assim, é possível construir a seção do usuário de forma mais consistente e automática.

O trabalho de Flexer et al. [2008] apresenta um modelo para geração de *playlists* baseada apenas na primeira e na última música. A ideia é criar uma transição suave, permitindo ao usuário a descoberta de novas músicas da coleção. Essa abordagem não utiliza meta dados e utiliza apenas a similaridade do áudio. Sendo assim, é necessária pouca interação do usuário para realizar a geração das sequências. A avaliação foi realizada com base nos gêneros e, os resultados mostraram na média, existe a necessidade de edição manual de algumas poucas músicas.

O trabalho de Hariri et al. [2012] apresenta um sistema de recomendação de música sensível ao contexto qual infere a informação contextual baseada nas sequências de músicas recentes dos usuários. A abordagem realiza mineração de *tags* para as mídias a partir de um site e usa a informação para determinar um conjunto de tópicos latentes

usando *Latent Dirichlet Allocation (LDA)*. A avaliação foi realizada sobre uma base de dados de *playlists* criadas manualmente, onde são analisados os padrões da sequência para recomendação de novas *playlists*.

## 2.2 Aprendizado de Máquina

O Aprendizado de Máquina, conforme Murphy [2012], é um campo de Ciência da Computação que explora o estudo de técnicas, muitas delas probabilísticas mas envolve diversas áreas, para produzir algoritmos capazes de aprender de uma tarefa. Ou seja, são algoritmos capazes de aprimorar a performance de seus resultados, conforme os dados fornecidos para treino. Este aprendizado pode é realizado com a utilização da computação de padrões para descrição coesa sobre o comportamento dos dados.

Normalmente, esses algoritmos trabalham com a criação de modelos capazes de realizar previsões sobre os dados, a partir de uma entrada de exemplo com objetivo de computar direções dos dados para tomar decisões. A construção destes modelos de aprendizado esta diretamente ligado a técnicas de otimização matemática, na tentativa de aprimorar soluções, minimizando uma função de perda ou erro, que deve medir a distância da solução ideal. O destaque dessas técnicas é aplicabilidade em diversos problemas como na classificação, agrupamento, regressão e inclusive em recomendação [Murphy, 2012].

### 2.2.1 Aprendizado Online e Reforço

O Aprendizado Online é uma importante sub área de Aprendizado de Máquina, aplicável principalmente quando a estrutura no comportamento dos dados é sequencial, ou seja, existem uma ordem sobre os dados. A principal diferença do Aprendizado Online é a proposta de atualizar o modelo aprendido conforme são realizadas novas interações [Bottou, 1998].

O Aprendizado por Reforço também é uma sub área de Aprendizado de Máquina, porém nesse caso a ideia é inspirada no comportamento psicológico. De forma geral, são modelos que concentram nas ações sobre o ambiente que maximizam um conceito de recompensa acumulativa. Basicamente, dado os estados atuais, um conjunto de ações, regras de transição e regras para determinar as recompensas e observações do ambiente, o algoritmo interage sobre o ambiente com intuito de maximar a recompensa observada pelas regras [Sutton & Barto, 1998].

Um exemplo prático desses modelos, é aplicabilidade em dados que ocorrem no tempo. Considerando o cenário de recomendação de músicas, cada mídia executada por

um usuário pode ser utilizada para atualizar um modelo personalizado para o usuário. Explorando ainda mais a ideia, o *feedback* do usuário ao ouvir cada mídia em sequência pode ser utilizado para reforçar o modelo, ou seja, o fato do usuário ouvir uma música pode recompensar o algoritmo ou o comando *skip* penalizar, inferindo sobre o *feedback* implícito que a música satisfaz ou não as preferências do usuário.

### 2.2.2 Aprendizado na Recomendação

Existem propostas na literatura para diversas áreas de aplicação das técnicas de Aprendizado de Máquina, Aprendizado Online e Reforço, apresentadas nas seções 2.2 e 2.2.1. Nesta seção serão destacados trabalhos relacionados a presente abordagem, porém com uma perspectiva centrada ao cenário de recomendação de músicas.

Hariri et al. [2015] propõe uma abordagem interativa para recomendação de músicas, adaptando a mudanças nas preferências dos usuários. A hipótese é que as preferências dos usuários podem mudar durante o tempo e, para capturar tais mudanças foi proposto um modelo, que estende a técnica de Aprendizado Online conhecida por *multi-armed bandit algorithms* ou algoritmo do bandido multi-armado.

A tese de Wang [2014] apresenta uma abordagem para recomendação de música a partir de uma formulação para balancear a exploração, quando a recomendação será diversificada, e aproveitamento para conseguir vantagem sobre o que já é conhecido. No entanto, a abordagem pode ser utilizada tanto para recomendação de músicas, quando para geração de *playlists*. Os resultados apresentaram ser efetivos, tendo como fruto desta tese o artigo de [Wang et al., 2014].

A dissertação de King [2014], apresenta um abordagem para recomendação de *playlist* utilizando Aprendizado por Reforço sobre agrupar de forma hierárquica conjuntos de sons para aprender preferências dos usuários. Foram extraídas características sobre as mídias e, a ideia é um software capaz de gerar listas consistentes dado a primeira música. Os resultados coletados foram bons, porém com experimentos realizados em um pequeno estudo de caso. No entanto, um dos resultados dessa dissertação é o trabalho de [King & Imbrasaitė, 2015], onde a mesma ideia é apresentada.

O trabalho de Liebman et al. [2015], também apresenta uma abordagem baseada em Aprendizado por Reforço para recomendação de sequências de músicas ou *playlists*. O modelo é baseado na semelhança entre sons e nas transições, além de ser adaptado para cada usuário. Para ajustar as transições, o modelo utiliza Cadeias de *Markov*, onde as músicas representam os estados. Outro diferencial do trabalho é a adequação do modelo, utilizado para isso o *feedback* explícito.

Já em Vall [2015] é apresentada uma proposta de tese e contem os caminhos

que o aluno seguirá. O objetivo é a geração de *playlists* automáticas baseado nos dados gerados pelo usuário. Como resultados parciais, é explorado um problema de recomendação de artistas novos usando os históricos e as atividades dos usuários usando *tags*. Outro fato interessante desse trabalho são os caminhos para trabalhos futuros que, onde o autor defende a ideia de utilização do *feedback* implícito para adaptação do modelo.

A presente proposta se assemelha com as demais citadas, pela construção de um modelo com objetivo de recomendar sequências musicais ou *playlists* de forma personalizada e automática. Porém, será explorado principalmente o *feedback* implícito, dado que melhor representa o comportamento dos usuários em sistemas de *streaming* de música, diferente das abordagens apresentadas que exigem o *feedback* explícito para atualização do modelo. Além disso, serão utilizados diferentes técnicas de Aprendizado Online e Reforço, tal como a combinação de outros modelos sem aprendizado.

## Capítulo 3

# Metodologia

Assim como são apresentadas novas abordagens para Recomendação, existem diversos trabalhos com foco em metodologias de avaliação. Muitas das propostas clássicas utilizam medidas de erro para verificar o quão distante a solução está do esperado. Nesse caso, métricas possíveis são, por exemplo, *Root Mean Square Error (RMSE)*, *Mean Absolute Error (MAE)*, entre outras. Essas métricas são utilizadas sobre dados contendo avaliações explícitas dos usuários sobre os itens e representam o erro médio entre as predições e o valor real.

Conforme os estudos de Cremonesi et al. [2010], a avaliação baseada em métricas de erro não reflete eficácia sobre sistemas reais. A proposta são métodos de avaliação baseados no ordenação, ou *ranking*, em que os itens são apresentados para um usuário. Dessa forma, é possível avaliar métodos utilizando métricas relacionadas a precisão no *ranking*, como *Mean Reciprocal Rank (MRR)*, *Mean Absolute Precision (MAP)*. A ideia dessas métricas é avaliar a posição dos relevantes no *ranking*.

A base de dados inicial para avaliação foi disponibilizada por Celma [2010]<sup>1</sup>. A mesma contém quase 1000 usuários distintos, observados no período de 2006 a 2010 na rede social para compartilhamento de músicas *lastfm*<sup>2</sup>. Ao todo, foram coletadas mais de 19 milhões de interações, contendo dados do usuário (Sexo, Idade, País e data de cadastro no sistema) e do histórico (código do usuário, data e hora do evento, código do artista, nome do artista, código da música, nome da música).

Contudo, para complementar os fatores descritivos das músicas, serão utilizados dados de enciclopédias de músicas, por exemplo, *Music Brainz*<sup>3</sup> [Swartz, 2002]. Com isso, é possível extrair diversas características das músicas como tamanho, artista, ano

---

<sup>1</sup><http://www.dtic.upf.edu/~ocelma/MusicRecommendationDataset/lastfm-1K.html>

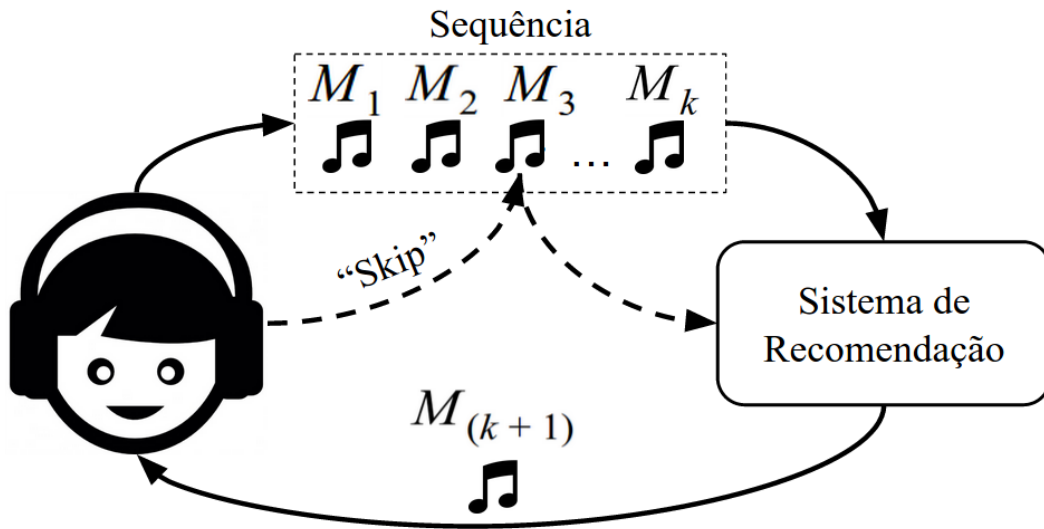
<sup>2</sup><http://www.last.fm/>

<sup>3</sup><http://www.musicbrainz.org/>

da gravação, além de dados observados por colaboradores, como é o caso das *tags* e das avaliações médias dos usuários.

A partir dos dados estruturados, os mesmos serão utilizados no treinamento dos algoritmos e na avaliação dos modelos propostos. Outra importante evidência que será utilizada, além das características, é o *feedback*. Assim como descrito, o *feedback* fornece um importante sinal sobre as preferências do usuário, e pode ser extraído de diversas formas, como por exemplo, as interações dos usuário. No cenário de músicas, podem ser considerados, por exemplo, *skip* como sinal negativo e o *play* como sinal positivo.

O trabalho explora a informação de *feedback* para treinamento de algoritmos de aprendizado online e criação de um modelo para recomendação. O principal objetivo é utilizar o *feedback* no formato implícito, ou seja, quando o usuário não declara sobre seus gostos, assim como no exemplo da Figura 3.1. Contudo, além de ser uma informação abundante em sistemas de *streaming* de música, carrega um significado implícito e que pode ser utilizada como fonte para a adaptação do modelo de aprendizado, tornando-o mais personalizável conforme as necessidades do usuário. Além disso, será um dado importante para modelar as mudanças de preferências.



**Figura 3.1.** Esboço sobre o funcionamento da metodologia

# Capítulo 4

## Cronograma

O cronograma contendo o planejamento das tarefas para o próximo ano do mestrado será descrito em 7 etapas descritas abaixo.

1. Processamento dos Dados

- Realizar processamento dos dados para extração de novas características.

2. Processamento de Características

- Tratamento de características relevantes para filtragem e inclusão de novas.

3. Revisão Bibliográfica

- Atualização dos conhecimentos sobre o assunto e percepção de tendências.

4. Implementação da Hipótese

- Codificação da hipótese afim de avaliar resultados.

5. Análise dos Resultados

- Avaliação dos resultados da hipótese e desenvolvimento de análises.

6. Escrita da Dissertação


- Documentação sobre todo o trabalho e revisão da escrita.



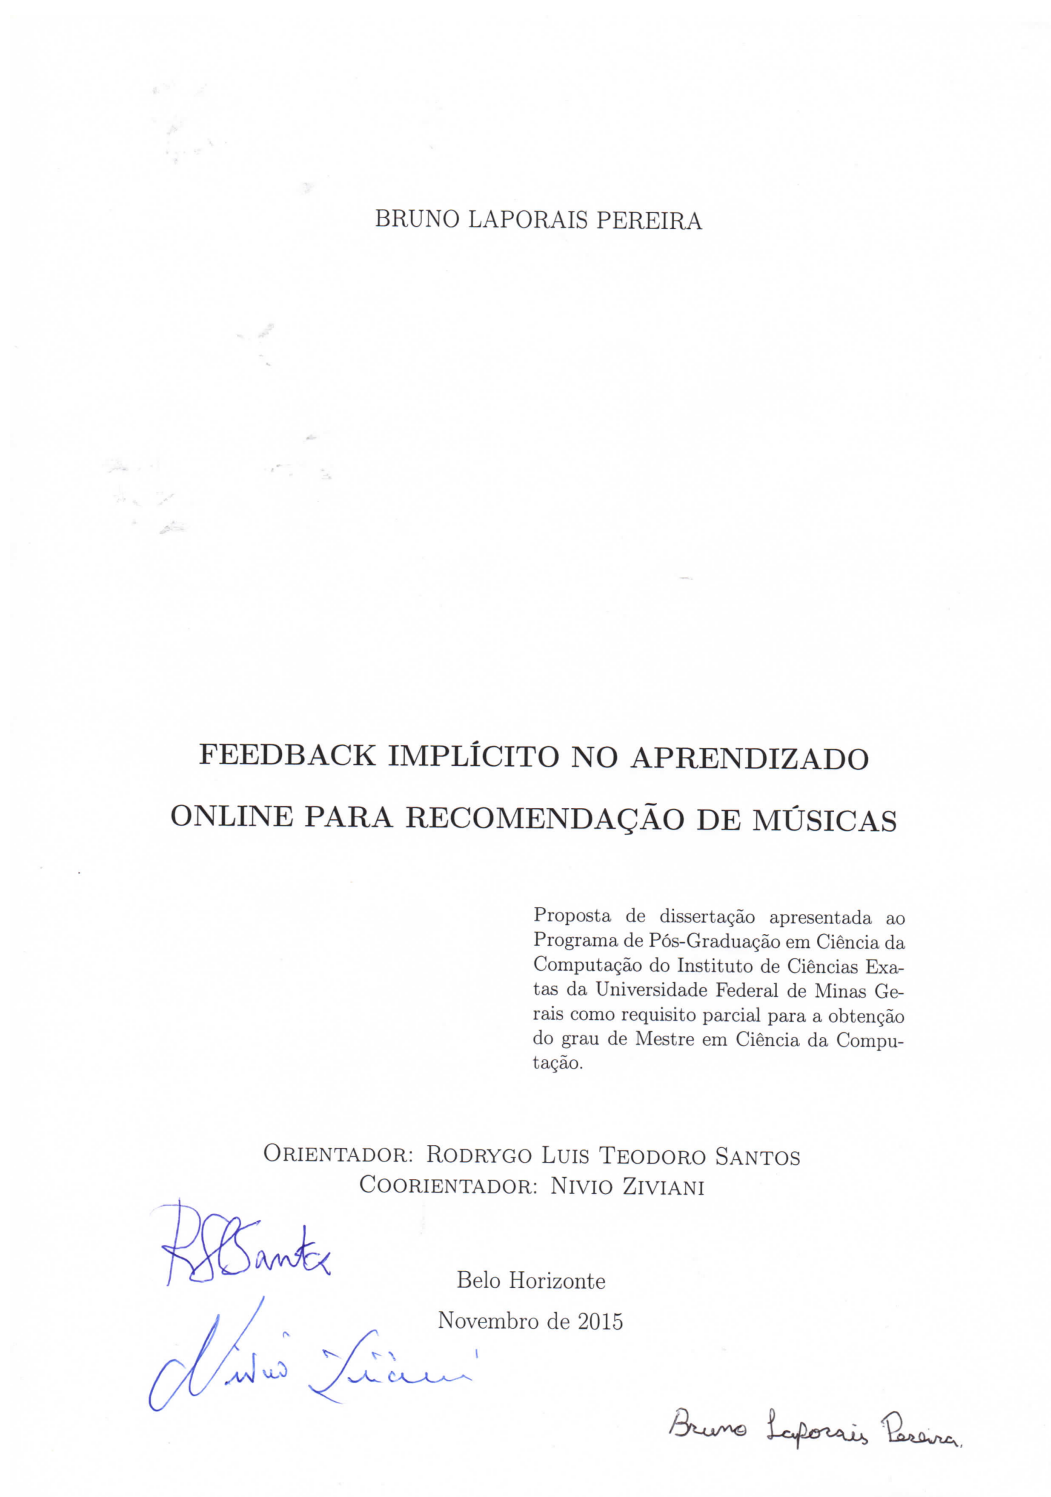


Apêndice A

Assinaturas



**Figura A.1.** Capa do projeto assinada pelo Orientador, Coorientador e Aluno



**Figura A.2.** Contra capa do projeto assinada pelo Orientador, Coorientador e Aluno

# Referências Bibliográficas

- Bottou, L. (1998). Online learning and stochastic approximations. *On-line learning in neural networks*, 17(9):25.
- Burke, R. (2002). Hybrid recommender systems: Survey and experiments. *User modeling and user-adapted interaction*, 12(4):331--370.
- Celma, O. (2010). *Music Recommendation and Discovery: The Long Tail, Long Fail, and Long Play in the Digital Music Space*. Springer.
- Cremonesi, P.; Koren, Y. & Turrin, R. (2010). Performance of recommender algorithms on top-n recommendation tasks. Em *Proceedings of the Fourth ACM Conference on Recommender Systems*, RecSys '10, pp. 39--46, New York, NY, USA. ACM.
- Flexer, A.; Schnitzer, D.; Gasser, M. & Widmer, G. (2008). Playlist generation using start and end songs. Em *ISMIR*, pp. 173--178.
- Hariri, N.; Mobasher, B. & Burke, R. (2012). Context-aware music recommendation based on latenttopic sequential patterns. Em *Proceedings of the sixth ACM conference on Recommender systems*, pp. 131--138. ACM.
- Hariri, N.; Mobasher, B. & Burke, R. (2015). Adapting to user preference changes in interactive recommendation. Em *Proceedings of the 24th International Conference on Artificial Intelligence*, pp. 4268--4274. AAAI Press.
- Herlocker, J. L.; Konstan, J. A.; Borchers, A. & Riedl, J. (1999). An algorithmic framework for performing collaborative filtering. Em *Proceedings of the 22nd annual international ACM SIGIR conference on Research and development in information retrieval*, pp. 230--237. ACM.
- Jawaheer, G.; Szomszor, M. & Kostkova, P. (2010). Comparison of implicit and explicit feedback from an online music recommendation service. Em *Proceedings of the 1st*

- International Workshop on Information Heterogeneity and Fusion in Recommender Systems*, HetRec '10, pp. 47--51, New York, NY, USA. ACM.
- King, J. & Imbrasaitė, V. (2015). Generating music playlists with hierarchical clustering and q-learning. Em *Advances in Information Retrieval*, pp. 315--326. Springer.
- King, J. V. (2014). Generating music playlists with reinforcement learning. Dissertação de mestrado, University of Cambridge.
- Koren, Y.; Bell, R. & Volinsky, C. (2009). Matrix factorization techniques for recommender systems. *Computer*, (8):30--37.
- Liebman, E.; Saar-Tsechansky, M. & Stone, P. (2015). Dj-mc: A reinforcement-learning agent for music playlist recommendation. Em *Proceedings of the 2015 International Conference on Autonomous Agents and Multiagent Systems*, pp. 591--599. International Foundation for Autonomous Agents and Multiagent Systems.
- Lops, P.; Gemmis, M. D. & Semeraro, G. (2011). Content-based recommender systems: State of the art and trends. Em *Recommender systems handbook*, pp. 73--105. Springer.
- Murphy, K. P. (2012). *Machine learning: a probabilistic perspective*. MIT press.
- Ricci, F.; Rokach, L. & Shapira, B. (2011). *Introduction to recommender systems handbook*. Springer.
- Sarwar, B.; Karypis, G.; Konstan, J. & Riedl, J. (2001). Item-based collaborative filtering recommendation algorithms. Em *Proceedings of the 10th international conference on World Wide Web*, pp. 285--295. ACM.
- Song, Y.; Dixon, S. & Pearce, M. (2012). A survey of music recommendation systems and future perspectives. Em *9th International Symposium on Computer Music Modeling and Retrieval*.
- Sutton, R. S. & Barto, A. G. (1998). *Reinforcement learning: An introduction*, volume 1. MIT press Cambridge.
- Swartz, A. (2002). Musicbrainz: A semantic web service. *IEEE Intelligent Systems*, 17(1):76--77. ISSN 1541-1672.
- Vall, A. (2015). Listener-inspired automated music playlist generation. Em *Proceedings of the 9th ACM Conference on Recommender Systems*, RecSys '15, pp. 387--390, New York, NY, USA. ACM.

- Volkovs, M. N. & Yu, G. W. (2015). Effective latent models for binary feedback in recommender systems.
- Wang, X. (2014). *Interactive Music Recommendation: Context, Content and Collaborative Filtering*. Tese de doutorado, National University of Singapore.
- Wang, X.; Wang, Y.; Hsu, D. & Wang, Y. (2014). Exploration in interactive personalized music recommendation: A reinforcement learning approach. *ACM Trans. Multimedia Comput. Commun. Appl.*, 11(1):7:1--7:22. ISSN 1551-6857.